KOCAELİ ÜNİVERSİTESİ

BÜYÜK VERİ ANALİZİNE GİRİŞ

TEKNİK PROJE RAPORU

Hazırlayanlar: Muhammet Fatih Şişmanoğlu,Yusuf Samet Karakurt,Onur Gökkaya
Okul Numaraları:210202021,220202021 ,220202052

1. Proje Mimarisi

Bu projede büyük veri teknolojileri kullanılarak uçtan uca çalışan gerçek zamanlı veri işleme ve makine öğrenmesi pipeline'ı geliştirilmiştir. Projenin temel amacı enerji tüketim verileri üzerinde analiz gerçekleştirmek, karbon yoğunluğu tahmini yapmak ve modern büyük veri mimarisini uygulamalı olarak oluşturmaktır.

Sistem mimarisi Docker tabanlı container yapısı üzerine kurulmuştur. Veri üretim katmanında Python Producer kullanılmış, Apache Kafka ile gerçek zamanlı veri akışı sağlanmış, Apache Spark Structured Streaming ile veri işleme gerçekleştirilmiş ve Delta Lake kullanılarak Bronze/Silver/Gold veri mimarisi oluşturulmuştur.

Makine öğrenmesi aşamasında Spark MLlib ile regresyon modelleri eğitilmiş ve sonuçlar MLflow ile kayıt altına alınmıştır. Son aşamada Streamlit dashboard ile tüm analizler görselleştirilmiştir.

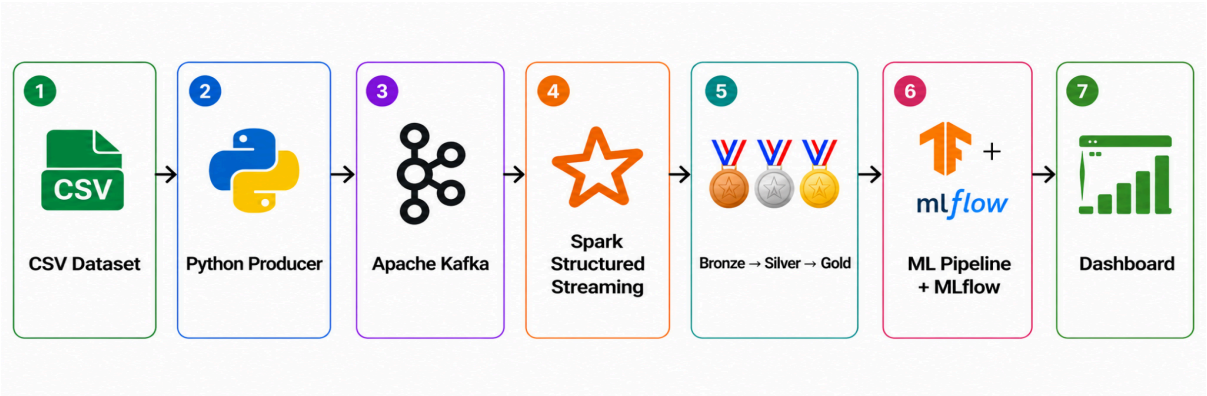

2. Docker ve Streaming Altyapısı

Projenin ilk aşamasında tüm servisler Docker Compose kullanılarak container ortamında yapılandırılmıştır. Sistem içerisinde Zookeeper, Kafka, Spark ve Python Producer servisleri birlikte çalışacak şekilde tasarlanmıştır.

Python Producer uygulaması CSV veri setini okuyarak Kafka topic'ine JSON mesajları göndermektedir. Gönderilen her mesaj içerisinde timestamp, user_id, event_type ve related_id alanları bulunmaktadır. Gerçek zamanlı veri akışı simülasyonu oluşturmak amacıyla mesaj gönderim süreleri rastgele gecikmeler ile ayarlanmıştır.

Kafka sistemi veri taşıma katmanı olarak kullanılmıştır. Spark Structured Streaming ise Kafka'dan gelen mesajları gerçek zamanlı olarak okuyarak veri işleme görevini üstlenmiştir.

3. Spark Structured Streaming ve Delta Lake

Kafka üzerinden gelen gerçek zamanlı veriler Spark Structured Streaming kullanılarak okunmuş ve JSON formatındaki mesajlar parse edilmiştir. Veri işleme sürecinde şema tanımlama, null temizleme ve duplicate kayıt temizleme işlemleri uygulanmıştır. Veriler Delta Lake mimarisinde üç farklı katmanda saklanmıştır:

- Bronze Katmanı → Ham streaming veri
- Silver Katmanı → Temizlenmiş ve düzenlenmiş veri
- Gold Katmanı → Analize hazır feature-engineered veri

Gold katmanında aşağıdaki özellikler üretilmiştir:

- renewable_ratio
- fossil_ratio
- gdp_per_capita
- energy_efficiency_score
- carbon_risk_score

Bu özellikler makine öğrenmesi modellerinde kullanılmıştır.

4. Makine Öğrenmesi Pipeline'ı

Makine öğrenmesi aşamasında Spark MLlib kullanılarak 5 farklı regresyon modeli eğitilmiştir:

- Linear Regression
- Decision Tree Regressor
- Random Forest Regressor
- Gradient Boosted Trees
- Generalized Linear Regression

Model performansları RMSE, MAE ve R^2 metrikleri kullanılarak değerlendirilmiştir. Ayrıca tüm deneyler MLflow ile kayıt altına alınmıştır.

Feature importance analizi ve residual analizleri gerçekleştirilerek modeller detaylı şekilde incelenmiştir.

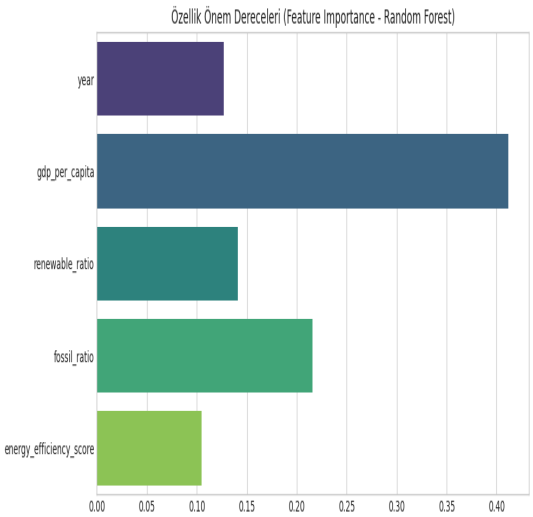

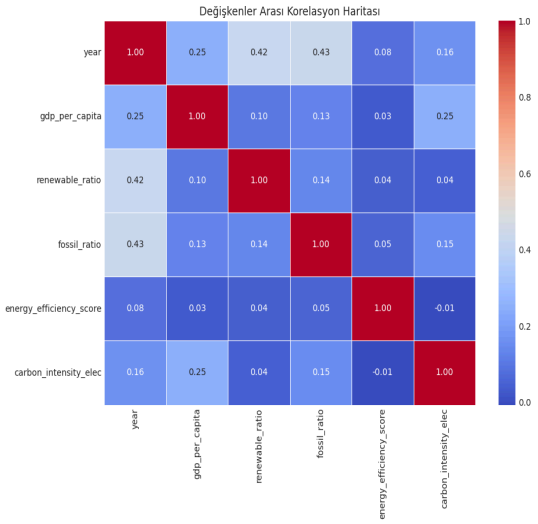

5.Dashboard ve Veri Görselleştirme

Projede Streamlit tabanlı interaktif dashboard geliştirilmiştir. Dashboard katmanı Gold veri katmanından üretilen işlenmiş verileri kullanmaktadır. Veri görselleştirme işlemlerinde Plotly Express kütüphanesi kullanılmıştır.

Dashboard içerisinde:

- karbon yoğunluğu trend analizi
- GDP ve enerji verimliliği ilişkisi
- yenilenebilir enerji dağılımı
- model performans karşılaştırmaları

görselleştirilmiştir.

Kullanıcılar sidebar filtreleri sayesinde yıl aralığı ve ülke seçimi yapabilmektedir. Ayrıca makine öğrenmesi modellerinin RMSE, MAE ve R^2 skorları dashboard üzerinden analiz edilebilmektedir. Bu yapı sayesinde büyük veri pipeline'ı sonucunda elde edilen veriler kullanıcı dostu ve interaktif şekilde sunulmuştur.

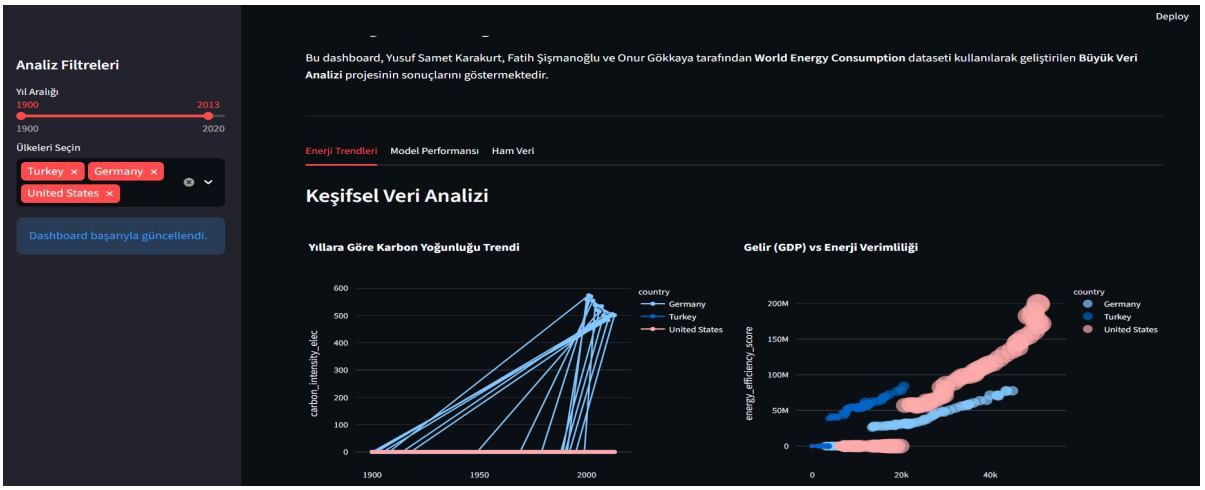

6. Sonuç ve Değerlendirme

Bu proje kapsamında gerçek zamanlı veri işleme, veri mühendisliği ve makine öğrenmesi süreçleri başarıyla uygulanmıştır. Apache Kafka ve Spark Structured Streaming kullanılarak büyük veri pipeline'ı geliştirilmiş, Delta Lake mimarisi ile güvenilir veri depolama sistemi oluşturulmuştur.

Makine öğrenmesi modelleri ile karbon yoğunluğu tahmini gerçekleştirilmiş ve sonuçlar dashboard üzerinden görselleştirilmiştir. Genel olarak proje; büyük veri teknolojileri, streaming veri işleme ve veri analitiği açısından başarılı ve profesyonel bir çalışma olmuştur.

Proje geliştirme sürecinde bazı teknik zorluklarla karşılaşılmıştır. Özellikle Docker container ağ yapısı, Kafka-Spark bağlantıları ve Spark paket sürüm uyumluluğu başlangıçta çeşitli sorunlara neden olmuştur. Ayrıca streaming veri işleme sırasında duplicate kayıtlar, checkpoint problemleri ve null veri temizleme süreçleri için ek düzenlemeler yapılmıştır. Dashboard tarafında ise büyük veri setlerinin görselleştirilmesi sırasında performans optimizasyonları uygulanmıştır.